



파이썬 세션 3주차

지도학습 전과정 실습

김희광

Contents

01 오프닝


02 퀴즈

03 데이터 전처리

04 실습 & 과제

01 오프닝

오프닝



한 회사의 인턴으로 일을 하고 있다고 가정 해보겠습니다

- 상황: 팀장님께서 .csv 파일을 주시면서 AI 모델을 돌리기 위해서 영화 데이터를 정리해달라고 요청

02 퀴즈

영화 '아바타'의 제작비는 얼마일까요?

A: 약 7백억

B: 약 3천억

C: 약 6천억



역대 최고 흥행작은 무엇일까요?



예산을 많이 쓰면 진짜 흥행할까?

어떤 장르가 제일 잘 팔릴까?

03 데이터 전처리

1단계: 데이터 건강검진

`df.info()` = X-ray

`df.describe()` = 혈액 검사

결측치 제거

	A	B	C
0	NaN	a	NaN
1	2.0	a	1.5
2	3.0	NaN	-0.3
3	4.0	b	NaN
4	5.0	b	4.2
5	NaN	b	NaN

2단계: 이상치 제거



숨어있는 쓰레기 데이터 찾는 과정

- 쓰레기 데이터를 쓰면 쓰레기 값이 나오기 때문
- 그럼 쓰레기 데이터를 구분하는 방법?
- NaN과 0은 다르다

=> 이럴때 불리언 인덱싱 기법을 활용하여 데이터를 거를수 있다

2단계: 이상치 제거

	국어	영어	수학
A	85	96	94
B	79	87	94
C	93	85	73
D	81	84	88

```
df['국어'] > 80
```

2단계: 이상치 제거

	국어	영어	수학
A	85	96	94
B	79	87	94
C	93	85	73
D	81	84	88

`df['국어'] > 80`

A	True
B	False
C	True
D	True

2단계: 이상치 제거

	국어	영어	수학
A	85	96	94
B	79	87	94
C	93	85	73
D	81	84	88



	국어	영어	수학
A	85	96	94
C	93	85	73
D	81	84	88

index가 B일때만
False 이므로
B만 빼고 가져온다
결국 국어열이 80점보다
큰 행만 남았다

`df['국어'] > 80`

A	True
B	False
C	True
D	True

3단계: 상관관계 분석

피어슨 상관계수

- 두 변수 간의 선형 관계의 강도와 방향을 측정하는 통계 지표다. 가장 널리 사용되는 상관계수로, 공분산을 각 변수의 표준편차로 나눈 값이다. 피어슨 상관계수는 -1에서 +1 사이의 값을 가진다.

Pearson Correlation Coefficient

$$r = \frac{n(\sum xy) - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}}$$



3단계: 상관관계 분석

특성 선택

- 주어진 원본 데이터에서 가장 좋은 성능을 보여줄 수 있는 데이터의 부분 집합(subset)을 찾아내는 방법

04 실습

실습

Step 1. 데이터 로드

Step 2. 퀴즈 정답 확인

Step 3. 데이터 전처리

Step 4. 특성 선택 (상관계수 Top 3)

앞으로의 파이썬 세션

앞으로의 파이썬 세션

원래

4주차: 비지도학습 전과정 실습

변경점

4주차: 오늘 준비한 데이터로 다음 주에 실제 AI 모델을 학습 시킬 예정